



Lista de Exercícios: Função de Ativação Softmax

A função softmax é uma extensão natural da função sigmoide para problemas de classificação multiclasse, transformando um vetor de scores em uma distribuição de probabilidade. Aqui estão três exercícios progressivos para consolidar seu entendimento desta função fundamental.

Exercício 1: Cálculo Fundamental e Interpretação de Probabilidades

Cenário: Um modelo de machine learning simples precisa classificar uma imagem entre três categorias: "Cachorro", "Gato" e "Pássaro". A camada de saída do modelo (antes da ativação) produziu os seguintes scores (logits):

- Cachorro: 2.0
- Gato: 1.0
- Pássaro: 0.1

Tarefa:

a) Calcule a probabilidade de cada classe usando a função softmax: $P(y_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$

b) Interprete os resultados. Qual classe o modelo previu como a mais provável e com qual confiança?

Resolução Passo a Passo:

Passo 1: Calcular e^{z_i} para cada classe

- $e^{2.0} = 7.389$
- $e^{1.0} = 2.718$
- $e^{0.1} = 1.105$

Passo 2: Calcular o denominador (soma de todos os exponenciais)

$$\sum_{j=1}^3 e^{z_j} = 7.389 + 2.718 + 1.105 = 11.212$$

Passo 3: Calcular as probabilidades softmax

- $P(\text{Cachorro}) = \frac{7.389}{11.212} = 0.659$ (65.9%)
- $P(\text{Gato}) = \frac{2.718}{11.212} = 0.242$ (24.2%)
- $P(\text{Pássaro}) = \frac{1.105}{11.212} = 0.099$ (9.9%)

Interpretação: O modelo previu "Cachorro" como a classe mais provável com **65.9% de confiança**. A diferença significativa entre as probabilidades indica que o modelo tem uma confiança razoável na sua predição, mas não absoluta.

Exercício 2: Efeito da Variação nos Scores de Entrada

Cenário: Considere o mesmo problema de classificação de animais. Um segundo modelo, após o treinamento, analisa a mesma imagem e produz scores diferentes, indicando maior certeza:

- Cachorro: 5.0
- Gato: 2.0
- Pássaro: 1.0

Tarefa:

- a) Calcule as novas probabilidades para essas três classes usando a função softmax.
- b) Compare as probabilidades resultantes com as do Exercício 1. O que a mudança na escala dos scores de entrada (maiores diferenças entre eles) causou nas probabilidades de saída?

Resolução Passo a Passo:

Passo 1: Calcular e^{z_i} para cada classe

- $e^{5.0} = 148.413$
- $e^{2.0} = 7.389$
- $e^{1.0} = 2.718$

Passo 2: Calcular o denominador

$$\sum_{j=1}^3 e^{z_j} = 148.413 + 7.389 + 2.718 = 158.52$$

Passo 3: Calcular as novas probabilidades

- $P(\text{Cachorro}) = \frac{148.413}{158.52} = 0.936$ (93.6%)
- $P(\text{Gato}) = \frac{7.389}{158.52} = 0.047$ (4.7%)
- $P(\text{Pássaro}) = \frac{2.718}{158.52} = 0.017$ (1.7%)

Comparação e Análise:

Classe	Exercício 1	Exercício 2	Diferença
Cachorro	65.9%	93.6%	+27.7%
Gato	24.2%	4.7%	-19.5%
Pássaro	9.9%	1.7%	-8.2%

Conclusão: Maiores diferenças entre os scores de entrada levaram a probabilidades mais "extremas". A softmax amplifica as diferenças relativas, criando uma distribuição mais concentrada na classe com maior score. Esta é uma característica importante que permite que modelos expressem diferentes níveis de confiança.

Exercício 3: Aplicação em Processamento de Linguagem Natural (NLP) - Predição da Próxima Palavra

Cenário: Um modelo de linguagem simples está tentando prever a próxima palavra na frase "O céu é...". Ele tem um vocabulário limitado de quatro palavras possíveis: "azul", "verde", "vermelho", "alto". Os scores (logits) gerados pelo modelo para a próxima palavra são:

- azul: 3.2
- verde: 1.5
- vermelho: 0.5
- alto: 2.8

Tarefa:

- Utilize a função softmax para converter esses scores em um vetor de probabilidades.
- Qual palavra é a mais provável de ser a próxima?
- Se o modelo estivesse usando uma função de ativação como a sigmoide (aplicada a cada saída individualmente), por que ela não seria a escolha ideal para esta tarefa?

Resolução Passo a Passo:

Passo 1: Calcular e^{z_i} para cada palavra

- $e^{3.2} = 24.533$
- $e^{1.5} = 4.482$
- $e^{0.5} = 1.649$
- $e^{2.8} = 16.445$

Passo 2: Calcular o denominador

$$\sum_{j=1}^4 e^{z_j} = 24.533 + 4.482 + 1.649 + 16.445 = 47.109$$

Passo 3: Calcular as probabilidades

- $P(\text{azul}) = \frac{24.533}{47.109} = 0.521$ (52.1%)
- $P(\text{verde}) = \frac{4.482}{47.109} = 0.095$ (9.5%)
- $P(\text{vermelho}) = \frac{1.649}{47.109} = 0.035$ (3.5%)
- $P(\text{alto}) = \frac{16.445}{47.109} = 0.349$ (34.9%)

Respostas:

- As probabilidades estão calculadas acima.
- A palavra **"azul"** é a mais provável (52.1% de probabilidade).
- Por que a sigmoide não seria ideal:**
 - A sigmoide aplicada individualmente a cada score produziria valores entre 0 e 1, mas não garantiria que a soma seja 1

- Não haveria uma distribuição de probabilidade válida
- A softmax garante que $\sum_{i=1}^K P(y_i) = 1$, criando uma distribuição de probabilidade real
- A softmax considera a relação entre todas as classes simultaneamente, não apenas cada uma isoladamente

Conclusão

A função softmax é fundamental para problemas de classificação multiclasse porque:

1. **Normalização:** Converte scores arbitrários em uma distribuição de probabilidade válida (soma = 1)
2. **Competição:** Amplifica as diferenças relativas entre classes, permitindo que o modelo expresse diferentes níveis de confiança
3. **Diferenciabilidade:** Permite o uso de backpropagation durante o treinamento
4. **Interpretabilidade:** Os resultados podem ser diretamente interpretados como probabilidades

A softmax é, portanto, a escolha natural quando queremos que um modelo escolha uma única classe entre múltiplas opções, mantendo a informação probabilística sobre a incerteza da predição.